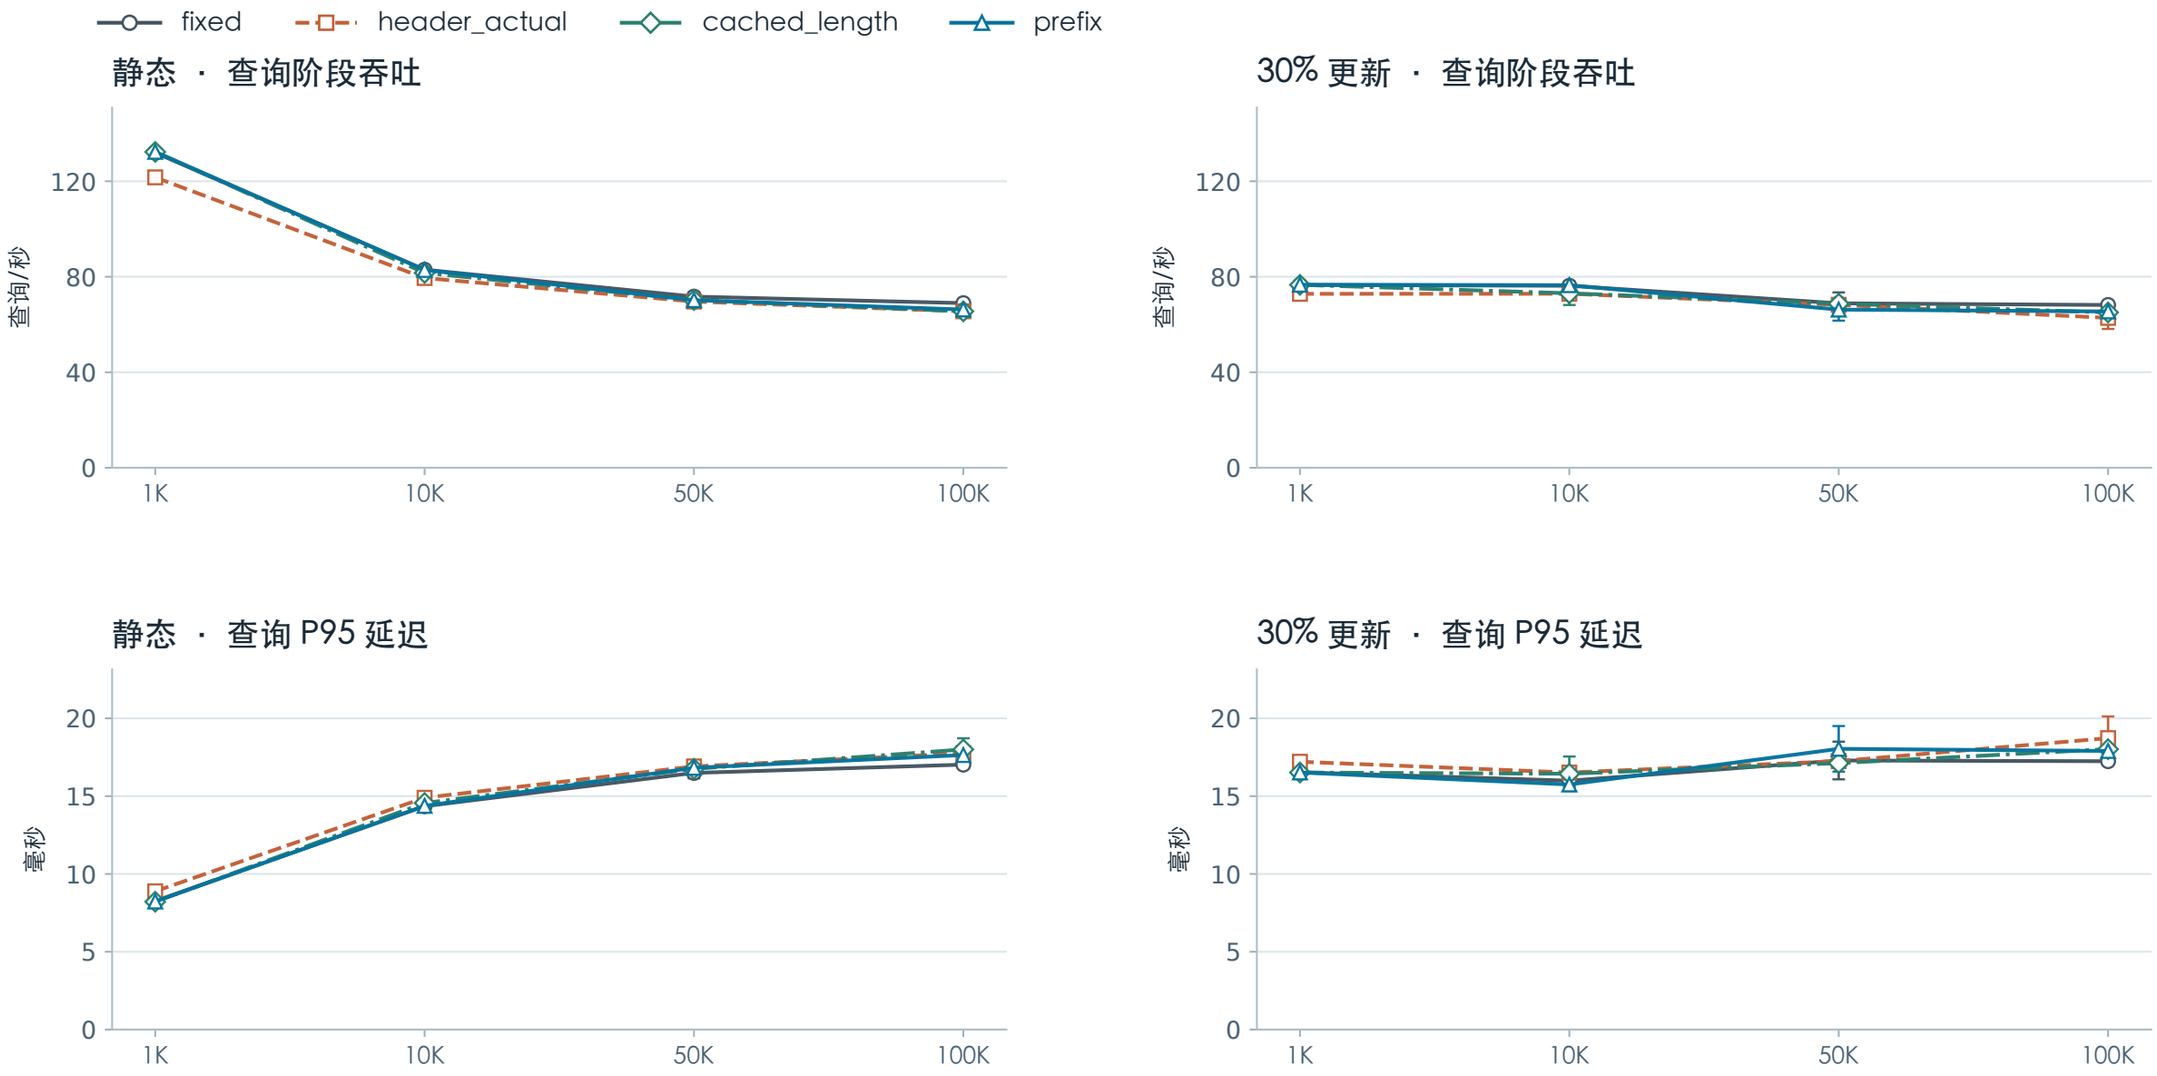
四档索引的查询性能

SIFT 1K / 10K / 50K / 100K。四种读取策略在各规模与负载下各测三轮。

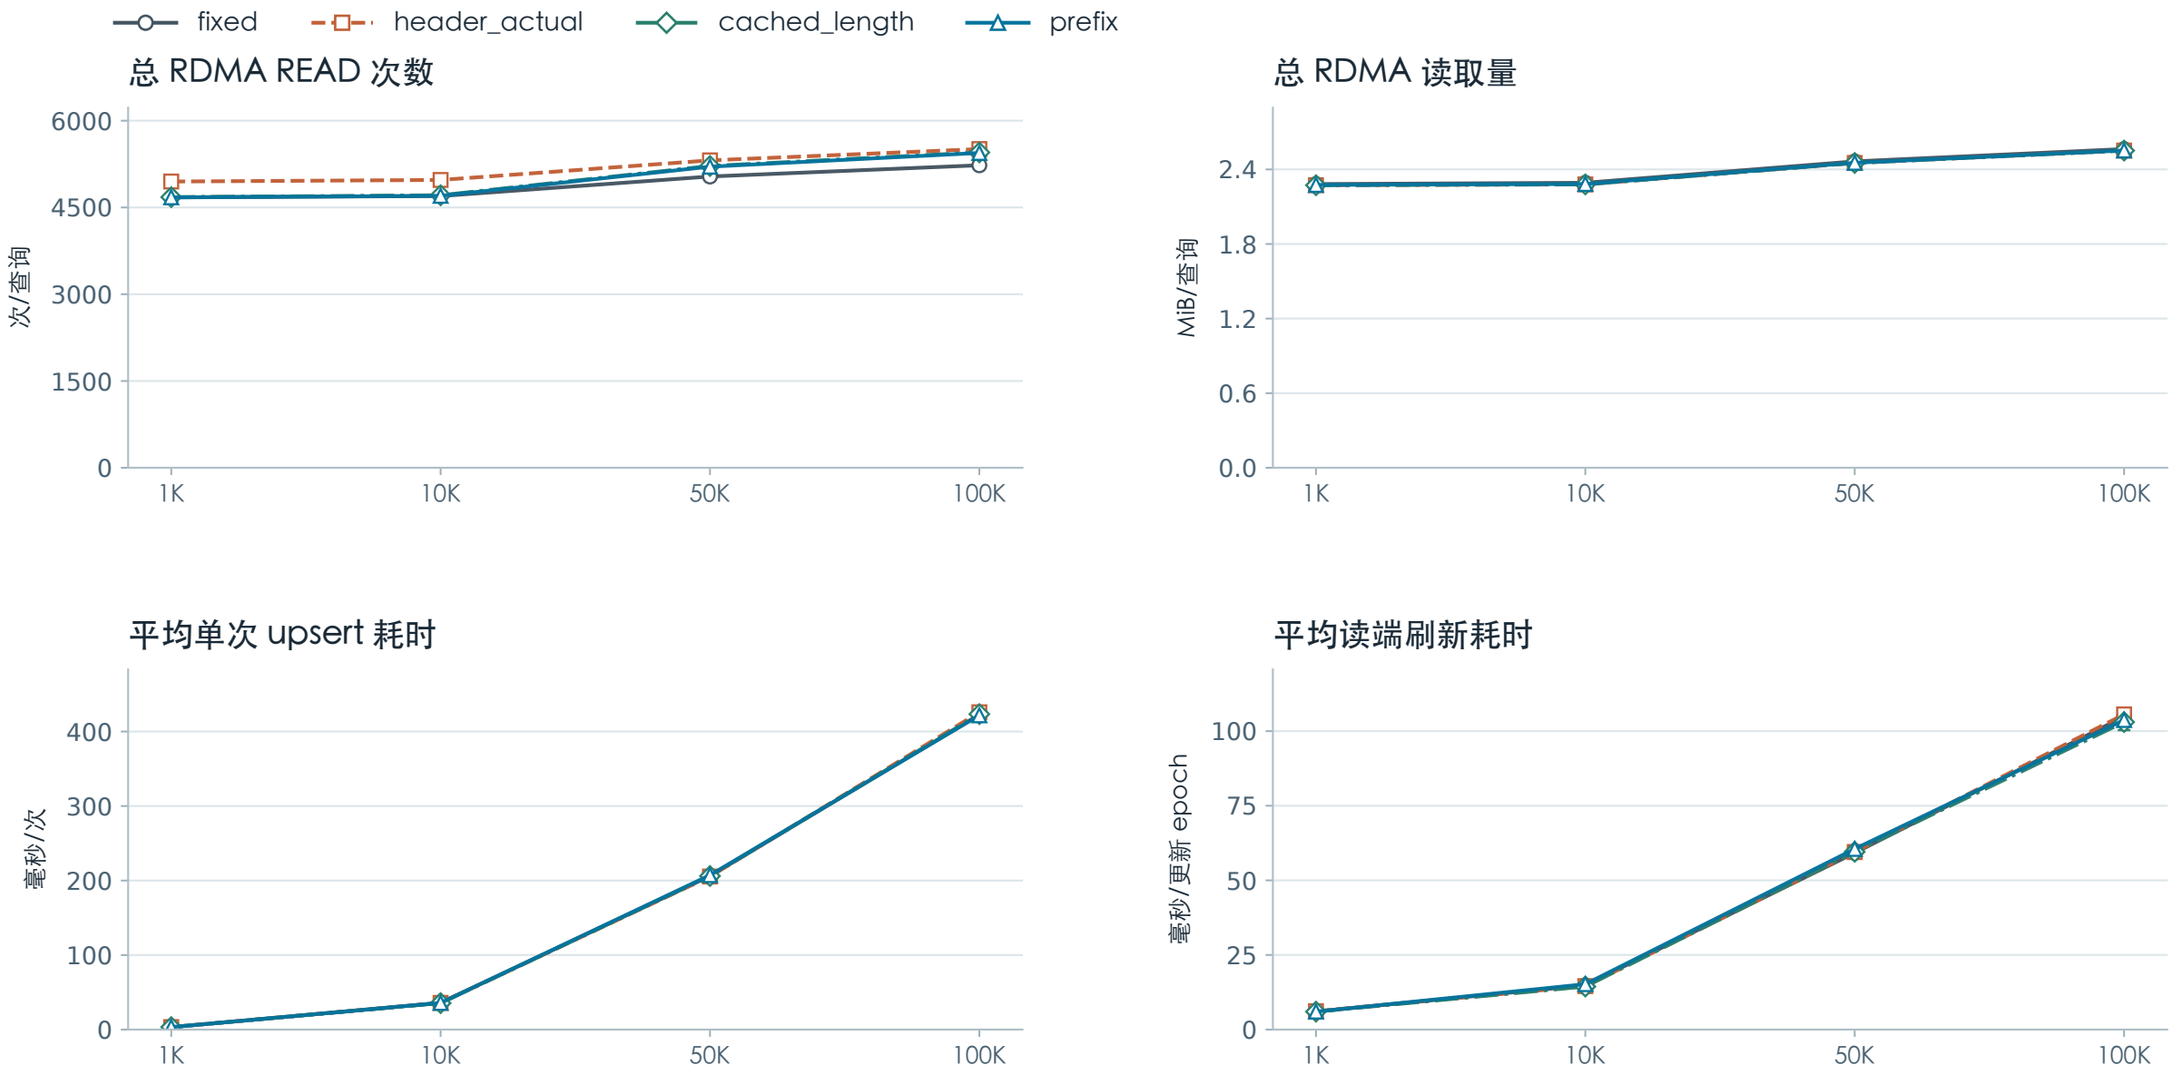


点为三轮均值，误差线为样本标准差。查询阶段吞吐以该阶段的查询数和墙钟时间计算。

统一设置为 M=16、efSearch=256、k=10、G=8、缓存容量 10,000、单读线程。混合负载为 30% 随机 upsert。

读取、更新与刷新开销

30% 随机更新负载。READ 指查询阶段完成的数据面 READ。



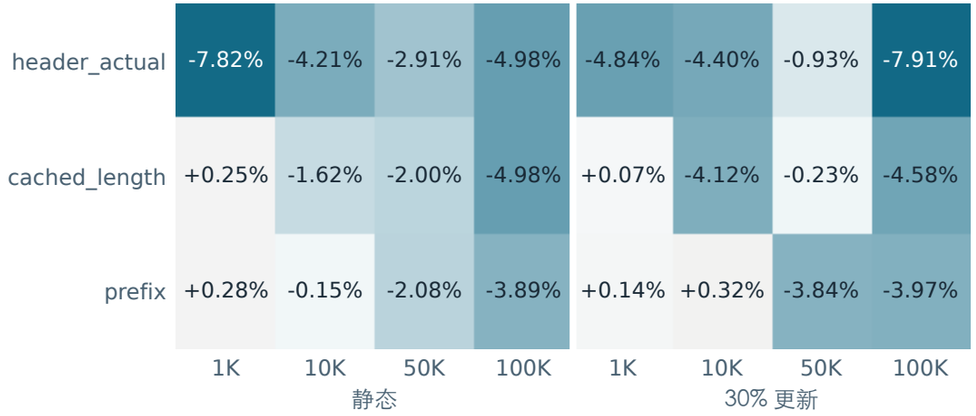
更新耗时包含提交、发布和写端目录刷新。读端刷新按有更新的 epoch 计。

读取次数与字节数按每查询统计。更新与刷新点为三轮均值，误差线为样本标准差。

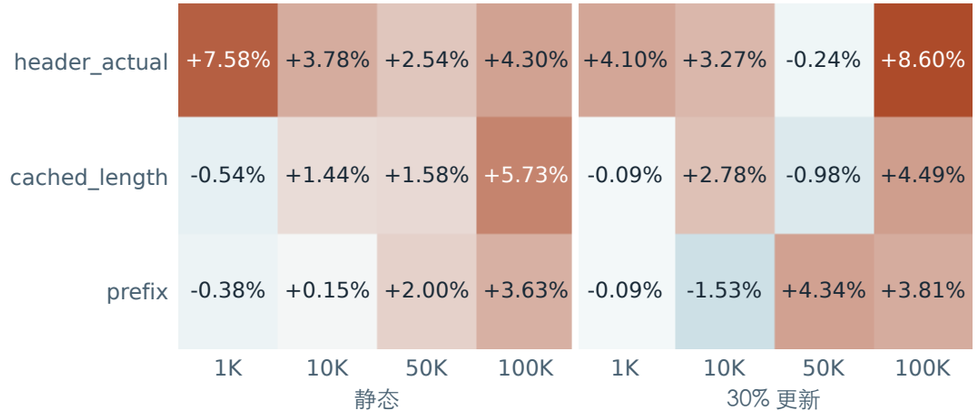
相对 fixed 的性能与读取变化

在相同规模和负载下，以 fixed 的三轮均值为分母。每格为策略均值 ÷ fixed 均值 - 1。

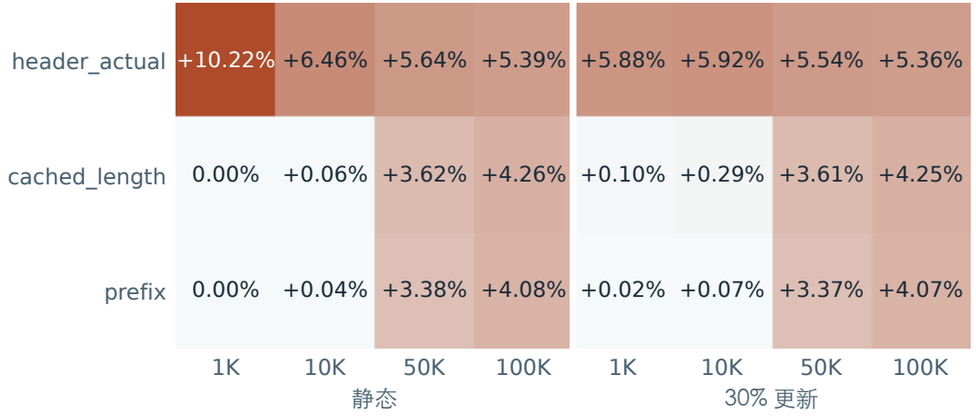
查询阶段吞吐



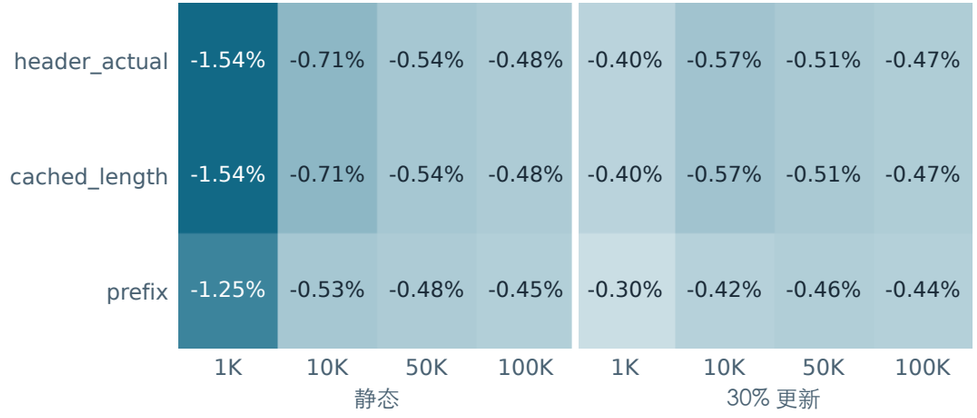
查询 P95 延迟



总 RDMA READ 次数



总 RDMA 读取量

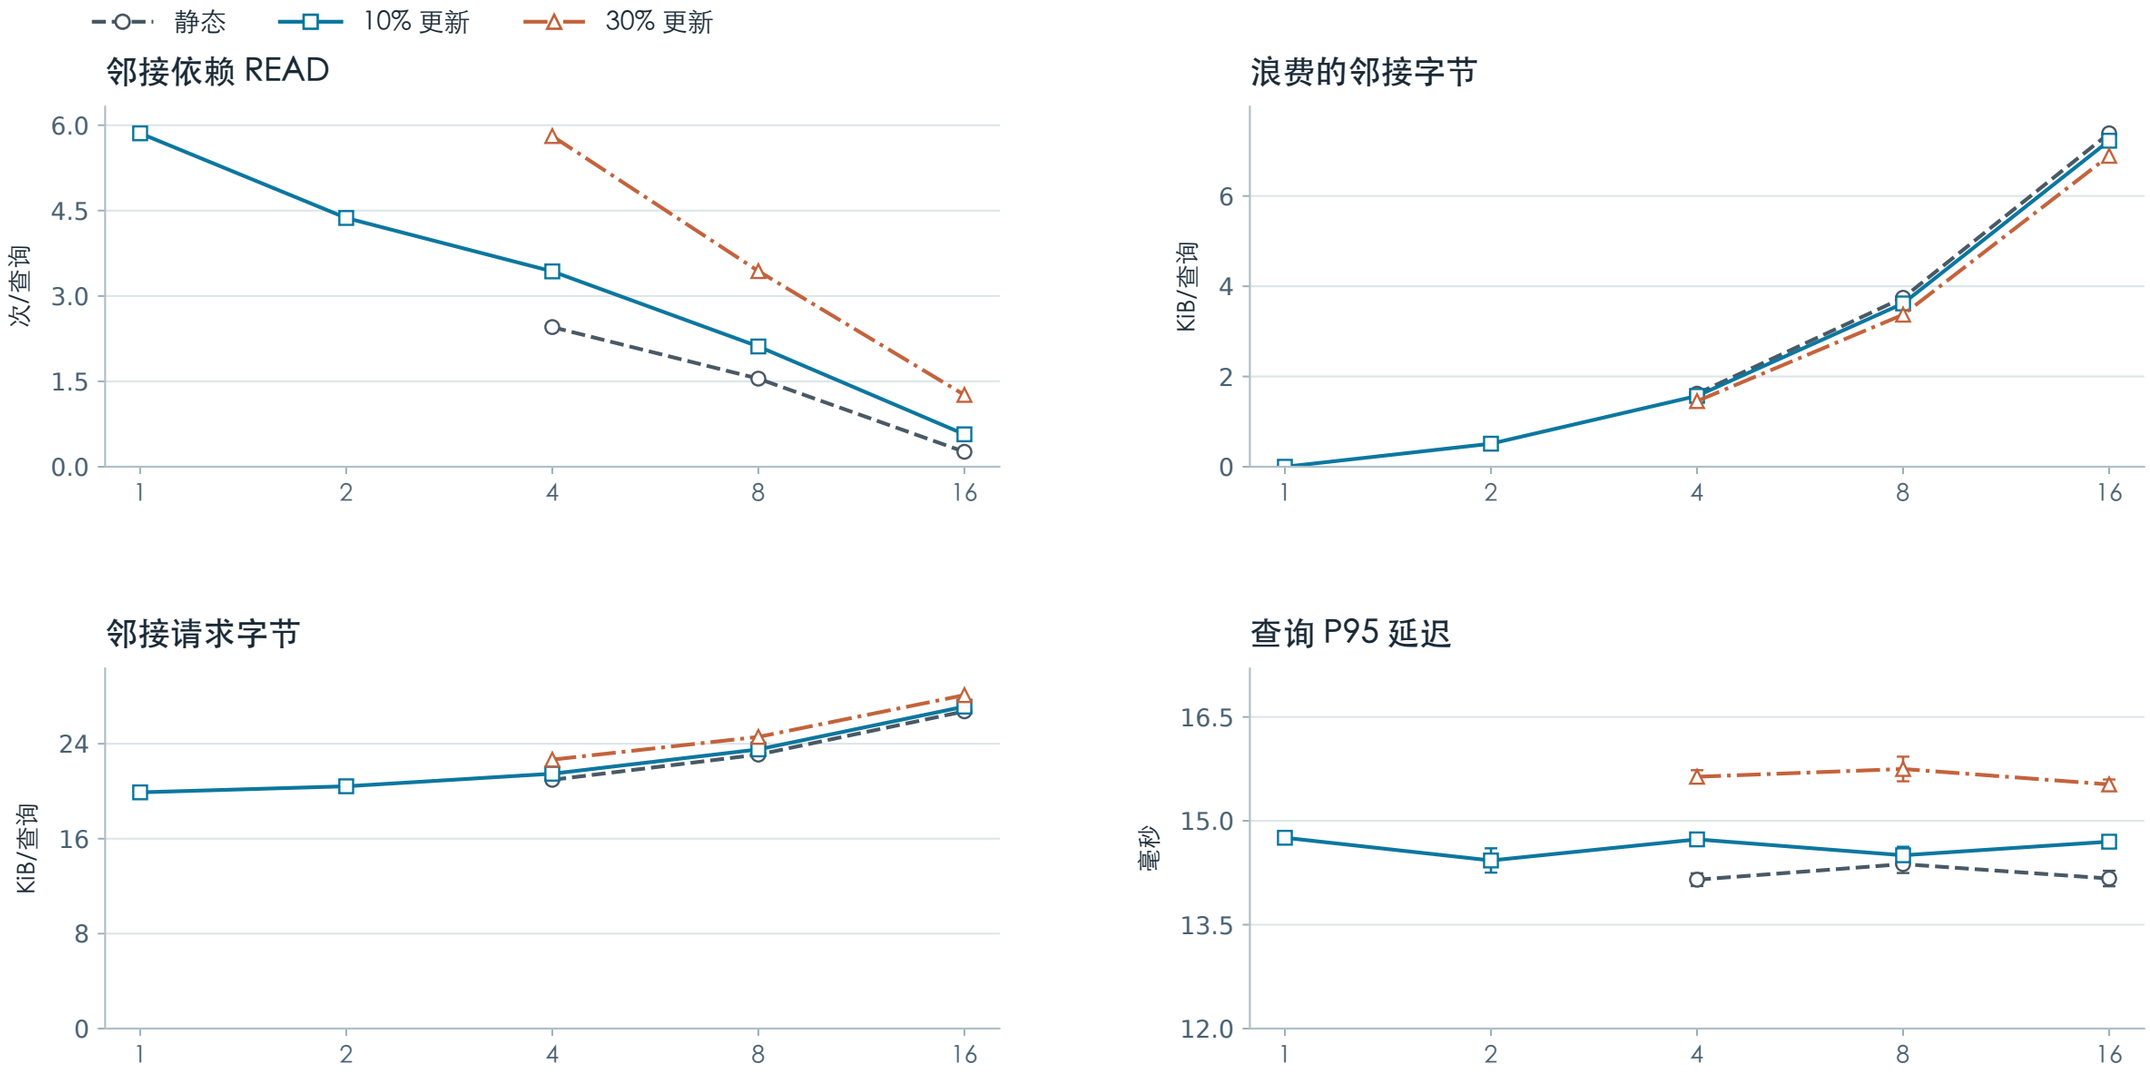


蓝色表示负值，橙色表示正值，各图色阶独立。

延迟和读取开销越低越好，吞吐越高越好。数值为百分比，绝对值见配套对比表。

粒度、依赖读取与邻接字节

prefix 策略。单读线程、缓存容量 10,000。静态、10% 和 30% 随机更新。



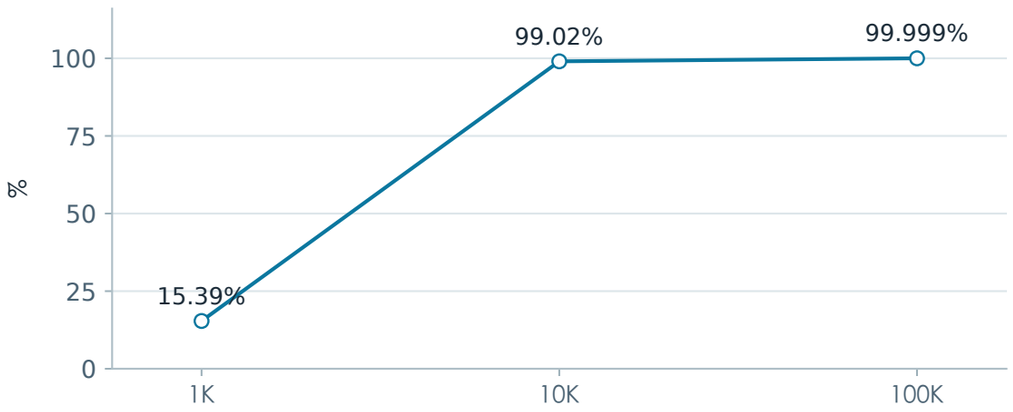
横轴为前缀长度分级步长 G，单位是邻居数。静态和 30% 更新覆盖 G=4/8/16，10% 更新覆盖 G=1/2/4/8/16。

延迟误差线为样本标准差。静态和 30% 的 G=8 来自四档主实验。

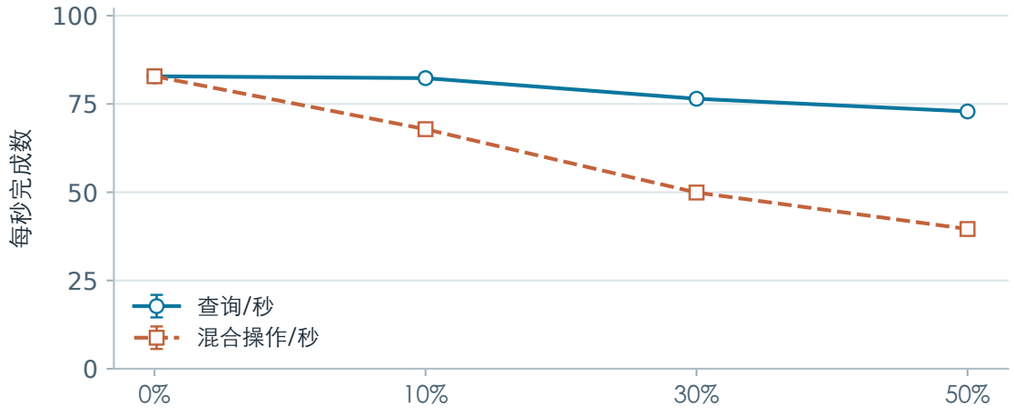
缓存容量与更新比例

prefix 策略，G=8、单读线程。容量实验使用 10% 更新，更新比例实验使用容量 10,000。

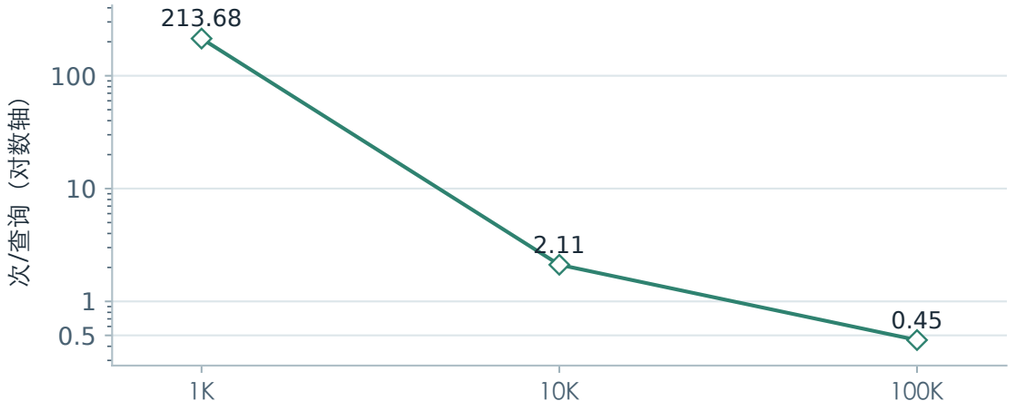
缓存命中率



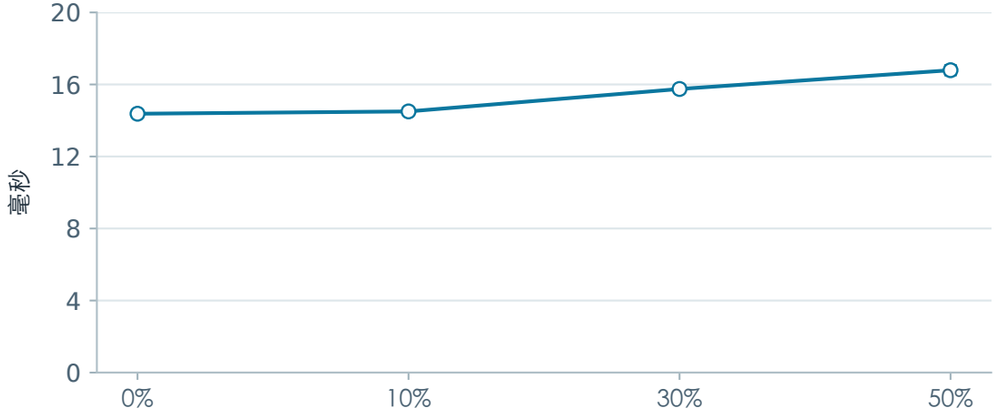
查询阶段与混合吞吐



邻接依赖 READ



查询 P95 延迟



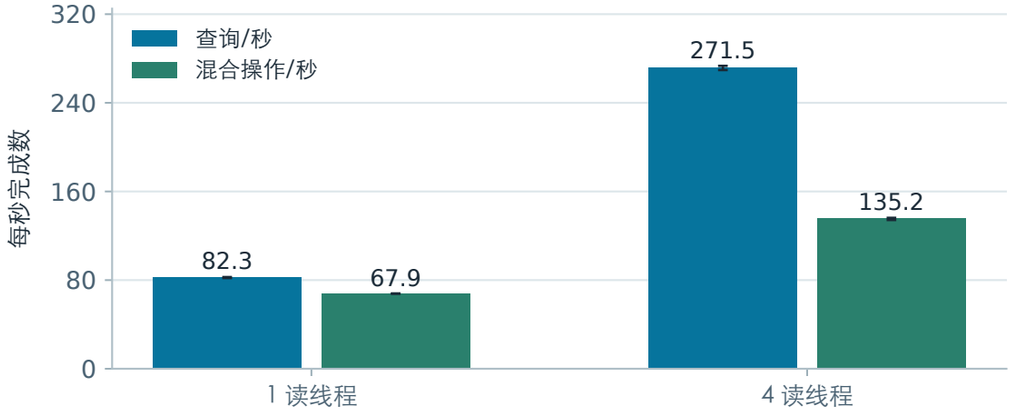
右侧使用随机更新。混合吞吐以查询和 upsert 的总数除以查询、更新和读端刷新三个阶段的耗时之和。

右图误差线为样本标准差。0% 和 30% 更新点复用四档主实验。

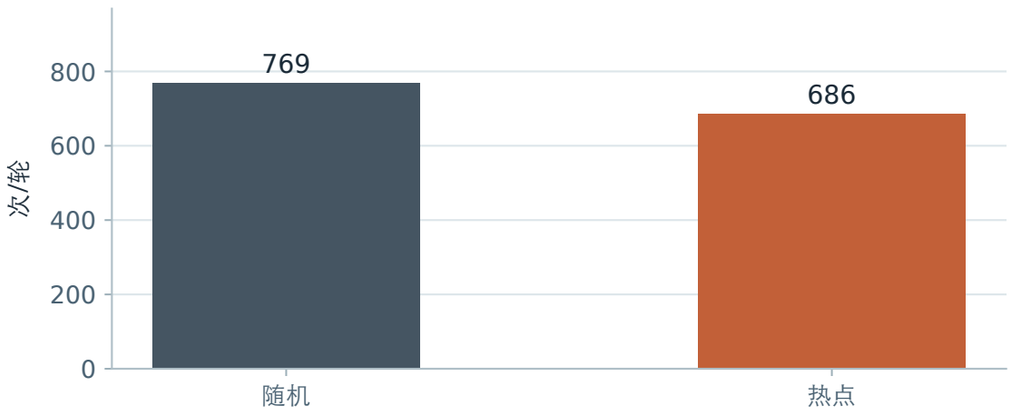
读线程数与更新目标分布

prefix 策略，G=8、容量 10,000、10% 更新。线程对照使用随机更新，分布对照使用单读线程。

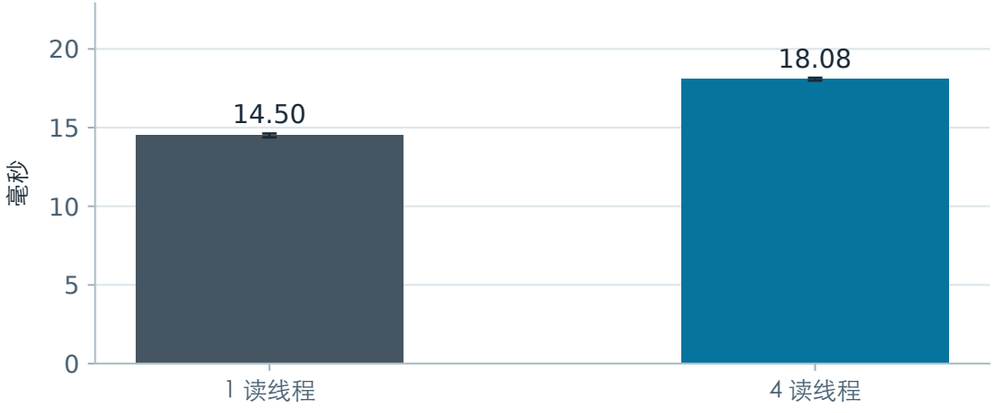
单读线程与四读线程吞吐



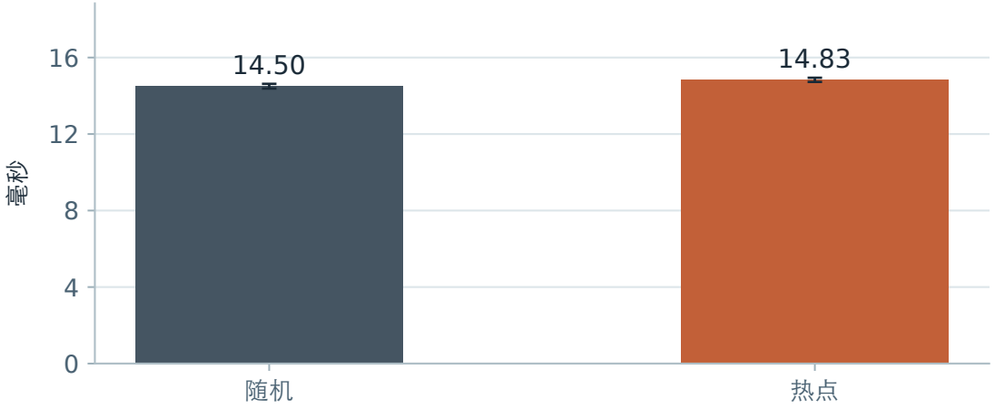
随机与热点更新的低估补读



读线程数与查询 P95



更新目标分布与查询 P95



每个读线程使用独立缓存并预热 1,000 次。吞吐与 P95 为三轮均值，误差线为样本标准差。

热点更新限定在前 1% 的节点。随机与热点保持操作顺序和向量引用一致，实际触及 199 和 85 个更新目标。